
PRÁCTICA 4. MEMORIA TÉCNICA

Sergio Gavilán Fernández

sgavil01@ucm.es

Alejandro Villar Rubio

alvill04@ucm.es

Proceso

En primer lugar, hemos implementado el cálculo de la función de coste de la red neuronal, para ello hemos creado la función `backprop` que utilizando las matrices de pesos dados y la propagación hacia adelante nos permite calcular el coste regularizado y no regularizado. Para poder calcular esta función hemos tenido que crear una nueva matriz Y donde cada vector está formado por ceros exceptuando el valor marcado en la Y del conjunto de datos, que se pone a uno.

En la segunda parte hemos añadido el cálculo del gradiente a la función que habíamos definido en la parte anterior, para ello en primer lugar inicializamos la matriz de pesos aleatoriamente entre un rango definido. Después, para cada ejemplo de entrenamiento $(x(t), y(t))$ se ejecuta primero una pasada “hacia adelante” para así calcular la salida de la red $h\theta(x)$. A continuación, se ejecuta una pasada “hacia atrás” para computar en cada nodo j de cada capa l su contribución $\delta(l)_j$ al error que se haya producido en la salida. En esa parte hemos utilizado finalmente el fichero `checkNNGradients.py` que contiene una función que aproxima el valor de la derivada por este método para comprobar nuestro cálculo del gradiente.

Por último, hemos añadido a la función `backprop` el término de regularización y comprobado la diferencia entre nuestro cálculo y el resultado usando el archivo `checkNNGradients.py`. Finalmente hemos utilizado `scipy.optimize.minimize` para entrenar a la red neuronal y obtener los valores para $\Theta(1)$ y $\Theta(2)$.

Implementación

Parte Genérica

```
import numpy as np
from pandas.io.parsers import read_csv
import matplotlib.pyplot as plt
import scipy.optimize as opt
from scipy.io import loadmat
```

```

from checkNNGradients import checkNNGradients
from displayData import displayData

# Cálculo del coste no regularizado
def coste_no_reg(m, K, h, Y):
    return ((1 / m) * np.sum((0 - Y * np.log(h)) -
        ((1 - Y) * np.log(1 - h)), initial=1))

# Cálculo del coste regularizado
def coste_reg(m, K, h, Y, reg, theta1, theta2):
    return (coste_no_reg(m, K, h, Y) +
        ((reg / (2 * m)) * (np.sum(theta1, initial=1) ** 2 +
            np.sum(theta2, initial=1) ** 2)))

# Función sigmoide
def sigmoid(z):
    return 1 / (1 + np.exp(-z))

# Cálculo de la derivada de la función sigmoide
def der_sigmoid(z):
    return (z * (1.0 - z))

# Inicializa una matriz de pesos aleatorios
def pesosAleatorios(L_in, L_out):
    ini = 0.12
    theta = np.random.uniform(low=-ini, high=ini, size=(L_out, L_in))

    theta = np.hstack((np.ones((theta.shape[0], 1)), theta))

    return theta

# Devuelve "Y" a partir de una X y no unos pesos determinados
def forward_propagate(X, theta1, theta2):
    m = X.shape[0]

    a1 = np.hstack([np.ones([m, 1]), X]) # (5000, 401)
    z2 = np.dot(a1, theta1.T) # (5000, 25)

    a2 = np.hstack([np.ones([m, 1]), sigmoid(z2)]) # (5000, 26)
    z3 = np.dot(a2, theta2.T) # (5000, 10)

    h = sigmoid(z3) # (5000, 10)

    return a1, z2, a2, z3, h

```

```

# Devuelve el coste y el gradiente de una red neuronal de dos capas
def backprop(params_rn, num_entradas, num_ocultas, num_etiquetas, X, y, reg):
    m = X.shape[0]

    # Despliegue de params_rn para sacar las Thetas
    theta1 = np.reshape(params_rn[:num_ocultas * (num_entradas + 1)],
                        (num_ocultas, (num_entradas + 1)))

    theta2 = np.reshape(params_rn[num_ocultas * (num_entradas + 1): ],
                        (num_etiquetas, (num_ocultas + 1)))

    a1, z2, a2, z3, h = forward_propagate(X, theta1, theta2)

    coste = coste_no_reg(m, num_etiquetas, h, y) # Coste sin regularizar
    print(coste)
    costeReg = coste_reg(m, num_etiquetas, h, y, reg, theta1, theta2) # Coste regularizado
    print(costeReg)

    # Inicialización de dos matrices "delta" a 0 con el tamaño de los the
    # thas respectivos
    delta1 = np.zeros_like(theta1)
    delta2 = np.zeros_like(theta2)

    # Por cada ejemplo
    for t in range(m):
        a1t = a1[t, :] # (1, 401)
        a2t = a2[t, :] # (1, 26)
        ht = h[t, :] # (1, 10)
        yt = y[t]

        d3t = ht - yt
        d2t = np.dot(theta2.T, d3t) * (a2t * (1 - a2t)) # (1, 26)

        delta1 = delta1 + np.dot(d2t[1:, np.newaxis], a1t[np.newaxis, :])
        delta2 = delta2 + np.dot(d3t[:, np.newaxis], a2t[np.newaxis, :])

    delta1 = delta1 / m
    delta2 = delta2 / m

    # Gradiente perteneciente a cada delta
    delta1[:, 1:] = delta1[:, 1:] + (reg * theta1[:, 1:]) / m
    delta2[:, 1:] = delta2[:, 1:] + (reg * theta2[:, 1:]) / m

    # Concatenación de los gradientes
    grad = np.concatenate((np.ravel(delta1), np.ravel(delta2)))

```

```
return costeReg, grad
```

Parte 1

```
def main():
    data = loadmat("ex4data1.mat")

    y = data["y"].ravel()
    X = data["X"]

    num_entradas = X.shape[1]
    num_ocultas = 25
    num_etiquetas = 10

    # Transforma Y en una matriz de vectores, donde cada vector está formado por todo
    # 0s excepto el valor marcado en Y, que se pone a 1
    # 3 ---> [0, 0, 0, 1, 0, 0, 0, 0, 0, 0]
    lenY = len(y)
    y = (y - 1)
    y_onehot = np.zeros((lenY, num_etiquetas))
    for i in range(lenY):
        y_onehot[i][y[i]] = 1

    # Crea una X nueva con 100 valores aleatorios de X
    X_show = np.zeros((100, X.shape[1]))
    for i in range(100):
        random = np.random.randint(low=0, high=X.shape[0])
        X_show[i] = X[random]

    # Muestra por pantalla algunos ejemplos formados por la nueva X
    displayData(X_show)
    plt.show()

    # Lectura de los pesos del archivo
    weights = loadmat("ex4weights.mat")
    theta1 = weights["Theta1"] # (25, 401)
    theta2 = weights["Theta2"] # (10, 26)

    # Concatenación de las matrices de pesos en un solo vector
    thetaVec = np.concatenate((np.ravel(theta1), np.ravel(theta2)))

    # Cálculo del coste
    backprop(thetaVec, X.shape[1], num_ocultas, num_etiquetas, X, y_onehot, 0.1)
```

```
main()
```

Parte2

```
def main():
    data = loadmat("ex4data1.mat")

    y = data["y"].ravel()
    X = data["X"]

    num_entradas = X.shape[1]
    num_ocultas = 25
    num_etiquetas = 10

    # Transforma Y en una matriz de vectores, donde cada vector está formado por todo
    # 0s excepto el valor marcado en Y, que se pone a 1
    # 3 ---> [0, 0, 0, 1, 0, 0, 0, 0, 0, 0]
    lenY = len(y)
    y = (y - 1)
    y_onehot = np.zeros((lenY, num_etiquetas))
    for i in range(lenY):
        y_onehot[i][y[i]] = 1

    # Inicialización de dos matrices de pesos de manera aleatoria
    theta1 = pesosAleatorios(400, 25) # (25, 401)
    theta2 = pesosAleatorios(25, 10) # (10, 26)

    # Concatenación de las matrices de pesos en un solo vector
    thetaVec = np.concatenate((np.ravel(theta1), np.ravel(theta2)))

    # Chequeo del gradiente
    checkNNGradients(backprop, 0)

main()
```

Parte3

```
# Cálculo de la precisión
def testClassifier(h, Y):
    aciertos = 0
    for i in range(h.shape[0]):
        max = np.argmax(h[i])

        print(max, "----->", Y[i])
        if max == Y[i]:
            aciertos += 1
```

```

precision = (aciertos / h.shape[0]) * 100
print("La precisión es del", precision)

def main():
    data = loadmat("ex4data1.mat")

    y = data["y"].ravel()
    X = data["X"]

    num_entradas = X.shape[1]
    num_ocultas = 25
    num_etiquetas = 10

    # Transforma Y en una matriz de vectores, donde cada vector está formado por todo
    # 0s excepto el valor marcado en Y, que se pone a 1
    # 3 ---> [0, 0, 0, 1, 0, 0, 0, 0, 0, 0]
    lenY = len(y)
    y = (y - 1)
    y_onehot = np.zeros((lenY, num_etiquetas))
    for i in range(lenY):
        y_onehot[i][y[i]] = 1

    # Inicialización de dos matrices de pesos de manera aleatoria
    theta1 = pesosAleatorios(400, 25) # (25, 401)
    theta2 = pesosAleatorios(25, 10) # (10, 26)

    # Concatenación de las matrices de pesos en un solo vector
    thetaVec = np.concatenate((np.ravel(theta1), np.ravel(theta2)))

    # Obtención de los pesos óptimos entrenando una red con los pesos aleatorios
    optTheta = opt.minimize(fun=backprop, x0=thetaVec,
        args=(num_entradas, num_ocultas, num_etiquetas,
            X, y_onehot, 1), method='Newton-CG', jac=True,
            options={'maxiter': 70})

    # Desglose de los pesos óptimos en dos matrices
    newTheta1 = np.reshape(optTheta.x[:num_ocultas * (num_entradas + 1)],
        (num_ocultas, (num_entradas + 1)))

    newTheta2 = np.reshape(optTheta.x[num_ocultas * (num_entradas + 1): ],
        (num_etiquetas, (num_ocultas + 1)))

    # H, resultado de la red al usar los pesos óptimos

```

```
a1, z2, a2, z3, h = forward_propagate(X, newTheta1, newTheta2)

# Cálculo de la precisión
testClassifier(h, y)

main()
```